Sveučilište u Zagrebu
Fakultet elektrotehnike i računarstva
Neuronske mreže · Projekt

Ocjena stadija dijabetičke retinopatije iz slika fundusa

Izvještaj 1 — Analiza podataka i pregled literature

Tim 06
Antonio Šimić (voditelj) · Jakov Malić
Josip Gregorić · Andrej Pavić

Zagreb, 8. studenoga 2026.

1. Opis problema

Dijabetička retinopatija (DR) komplikacija je šećerne bolesti u kojoj povišena glukoza oštećuje krvne žile mrežnice. Jedan je od vodećih uzroka sljepoće radno aktivne populacije, a u ranim stadijima protječe bez simptoma — pacijent primijeti pogoršanje tek kada su oštećenja već znatna. Zato se provode programi probira u kojima se snima fundus (očna pozadina) i snimka ručno ocjenjuje, što zahtijeva oftalmologa i predstavlja usko grlo.

Ocjene se dodjeljuju prema međunarodnoj kliničkoj skali težine DR [1], koja pet stadija definira vrstom, brojem i položajem lezija: **0 – No DR** (bez znakova), **1 – Mild** (samo mikroaneurizme), **2 – Moderate**, **3 – Severe** (opsežna krvarenja u sva četiri kvadranta, venozno nizanje ili IRMA) i **4 – Proliferative** (neovaskularizacija). Naš je zadatak **klasifikacija slike u jedan od pet uređenih razreda**.

Dvije osobine zadatka oblikuju analizu koja slijedi. Oznake su **ordinalne**, pa zamjena stadija 0 i 4 nije jednako teška pogreška kao zamjena 2 i 3 — obična točnost zato nije prikladna mjera. Snimke nastaju na **različitim uređajima i u nekontroliranim uvjetima**, zbog čega tehnička svojstva snimke postaju mogući izvor curenja podataka, što se u analizi pokazalo glavnim nalazom.

2. Skup podataka

Koristimo skup **APTOS 2019 Blindness Detection** [9], objavljen na Kaggleu u sklopu natjecanja društva *Asia Pacific Tele-Ophthalmology Society*. Snimke potječu iz programa probira bolnice *Aravind Eye Hospital* u ruralnim područjima Indije, gdje su snimatelji putovali na terenske lokacije — što objašnjava izraženu varijabilnost kvalitete.

Oznake su javno dostupne samo za dio za treniranje; oznake službenog testnog dijela zadržane su za vrednovanje na natjecanju. Zato sve svoje skupove izvodimo iz označenog dijela, a neoznačeni ne koristimo.

Ulaz je RGB fotografija fundusa u PNG formatu s tri 8-bitna kanala — krug mrežnice upisan u crnu pravokutnu pozadinu, čiji se udio znatno razlikuje među snimkama. **Oznaka** je jedan cijeli broj `diagnosis` $\in \{0, 1, 2, 3, 4\}$ po slici, bez oznaka pojedinih lezija, maski segmentacije ili okvira.

Prateći metapodaci su minimalni: `train.csv` sadrži samo `id_code` i `diagnosis`. Nema podatka o pacijentu, oku (lijevo/desno), uređaju ni vremenu snimanja. **Zbog toga slike ne možemo grupirati po pacijentu** — ograničenje na koje se vraćamo u poglavljima 6 i 7.

Tablica 1. Veličina skupa podataka.

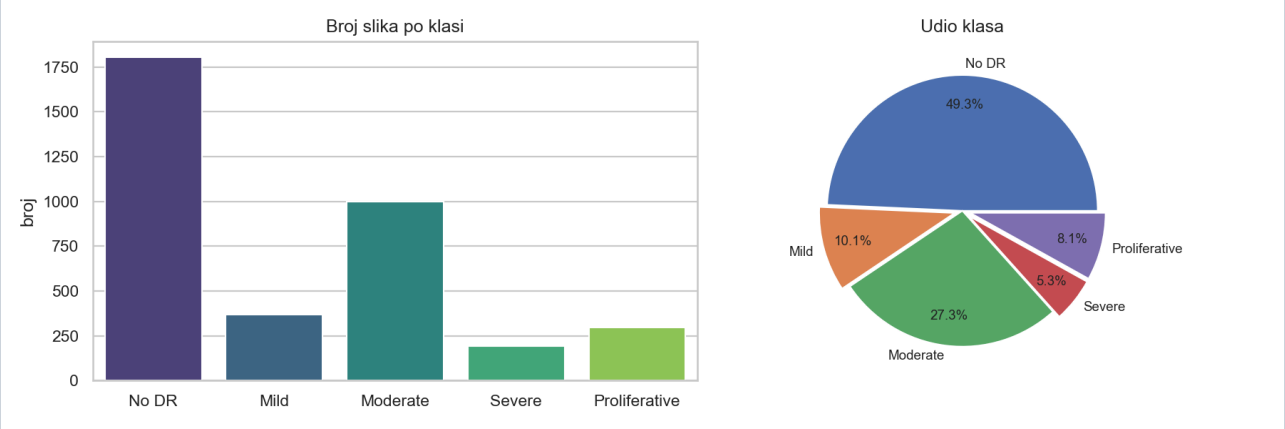
Označene slike (`train.csv`)	3662
Slike prisutne na disku	3662
Neoznačene slike (ne koristimo)	1928
Ukupna veličina označenih slika	8,6 GB
Broj različitih rezolucija	17

3. Raspodjela oznaka

Raspodjela je **izrazito neuravnotežena**: omjer najčešće i najrjeđe klase iznosi **9,4×**. Snimke bez nalaza čine 49,3 % skupa, dok najrjeđa klasa (Severe) ima manje od 200 primjera.

Tablica 2. Broj i udio slika po klasi.

Oznaka	Klinički stadij	Broj slika	Udio (%)
No DR	0 – bez retinopatije	1805	49,3
Mild	1 – blaga neproliferativna	370	10,1
Moderate	2 – umjerena neproliferativna	999	27,3
Severe	3 – teška neproliferativna	193	5,3
Proliferative	4 – proliferativna	295	8,1
Ukupno		**3662**	**100,0**

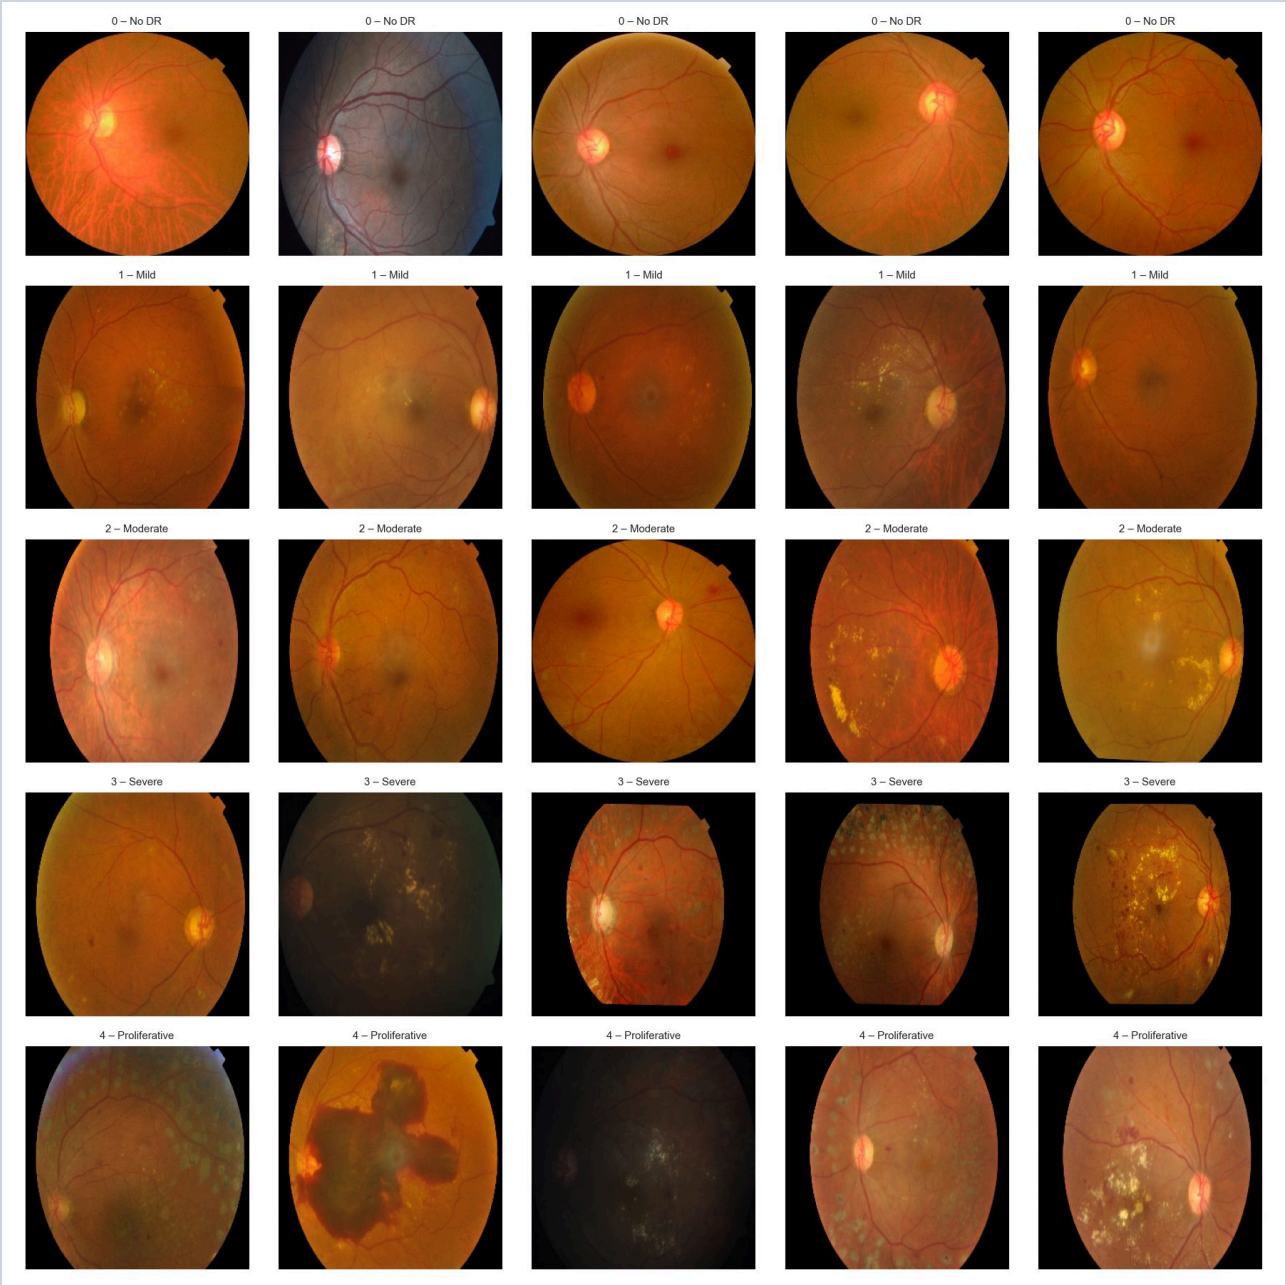


Slika 1. Raspodjela oznaka — broj slika (lijevo) i udio (desno).

Neuravnoteženost je očekivana za populaciju na probiru, u kojoj je većina pregledanih bez nalaza. Napominjemo ipak da **točni udjeli nisu populacijska prevalencija**: udio od 27,3 % za stadij 2 znatno je viši od onoga što bi se očekivalo u općoj populaciji dijabetičara, pa je sastav skupa i posljedica načina prikupljanja i odabira snimaka, a ne samo epidemiologije.

Posljedice za vrednovanje su dvije. Model bez korekcije ima snažan poticaj predviđati česte klase, čime propušta upravo pacijente kojima je pregled najpotrebniji. I **točnost postaje obmanjujuća**: trivijalan model koji sve proglasi zdravim već postiže 49,3 % točnosti. Zato kao glavnu mjeru planiramo kvadratno ponderiranu kappu (QWK), koja uzima u obzir i ordinalnost i neuravnoteženost.

Korisne su i binarne perspektive. Klinički je relevantan **prag upućivanja specijalistu**, koji literatura [2], [3] postavlja na klase ≥ 2: tada skup ima **1 487** snimaka za upućivanje naspram **2 175** ostalih. Podjela „ima li uopće DR“ (0 naspram > 0) daje 1 805 : 1 857, ali ona ne odgovara kliničkoj odluci jer stadij 1 u pravilu ne zahtijeva upućivanje.



Slika 2. Slučajni primjeri iz svake klase (redovi 0–4). Uočljiva je velika razlika u osvjetljenju, nijansi i udjelu crne pozadine među snimkama *iste* klase.

4. Osnovna statistika slikovnih značajki

Ulazi su slike, pa smo osnovnu statistiku izračunali nad izvedenim značajkama koje opisuju tehnička svojstva snimke: dimenzije i omjer stranica, veličinu datoteke, srednji intenzitet po kanalu, svjetlinu i standardnu devijaciju sivih razina kao mjeru kontrasta (oboje *unutar područja oka*, uz masku intenziteta > 10, da crna pozadina ne iskrivi vrijednosti), oštrinu te udio tamne pozadine.

Oštrinu mjerimo varijancom Laplacijana, ali u **dvije inačice**. Sirova `sharpness` računa se na snimci u izvornoj rezoluciji i zato *mjeri uglavnom rezoluciju*, a ne zamućenost — njezina korelacija sa širinom iznosi **-0,86**. Zbog toga uvodimo `sharpness_norm`, mjerenu nakon svođenja svake snimke na istu veličinu (512×512), koja je usporediva među snimkama različite rezolucije. U analizi kvalitete koristimo isključivo normaliziranu inačicu.

Tablica 3. Osnovna statistika izvedenih značajki (N = 3662).

Značajka	Prosjek	Std. dev.	Min	Medijan	Max
Širina (px)	2015,18	884,3	474	2144	4288
Visina (px)	1526,83	542,66	358	1536	2848
Omjer stranica	1,28	0,18	1	1,33	1,51
Veličina datoteke (kB)	2294,22	1721,14	216,54	1889,6	7494,43
Svjetlina (unutar oka)	87,7	20,79	27,65	91,07	155,82
Kontrast (std. dev. sivih razina)	17,61	5,76	5,88	16,56	55,84
Oštrina, sirova (var. Laplacijana)	145,41	127,99	9,08	85,9	1413,78
Oštrina, normalizirana (512×512)	29,53	19,75	1,86	22,25	162,07
Udio crne pozadine	0,23	0,13	0	0,21	0,53
Srednji R	138,72	35,92	34,87	146,49	237,81
Srednji G	74,18	18,86	22,56	76,26	147,76
Srednji B	23,45	16,35	0,05	19,67	105,6

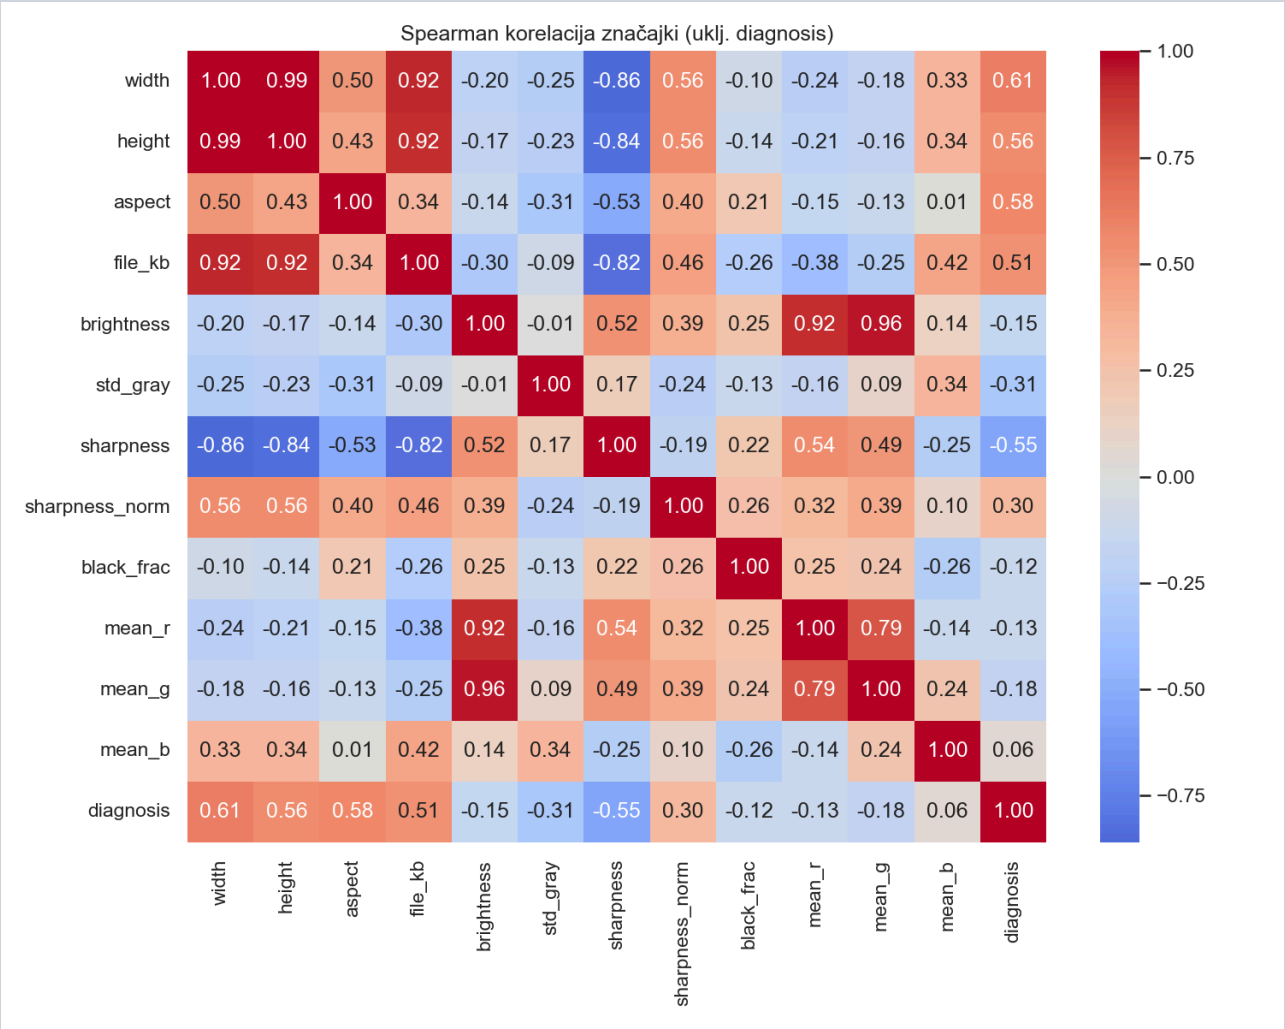
Tri su nalaza bitna. **Rezolucija nije ujednačena** (17 različitih vrijednosti), pa je svođenje na zajedničku dimenziju nužno. **Svjetlina i kontrast izrazito variraju**, što potvrđuje da su snimke nastale u nekontroliranim uvjetima. I **veličina datoteke razlikuje se za više od reda veličine**, što je također posljedica razlike u rezoluciji.

5. Odnosi među značajkama i curenje podataka

Ovo je poglavlje donijelo najvažniji nalaz analize. Spearmanove korelacije pokazuju da **nekoliko tehničkih značajki snažno korelira s oznakom** (Tablica 4, Slika 3).

Tablica 4. Značajke najjače povezane s oznakom (Spearmanov ρ).

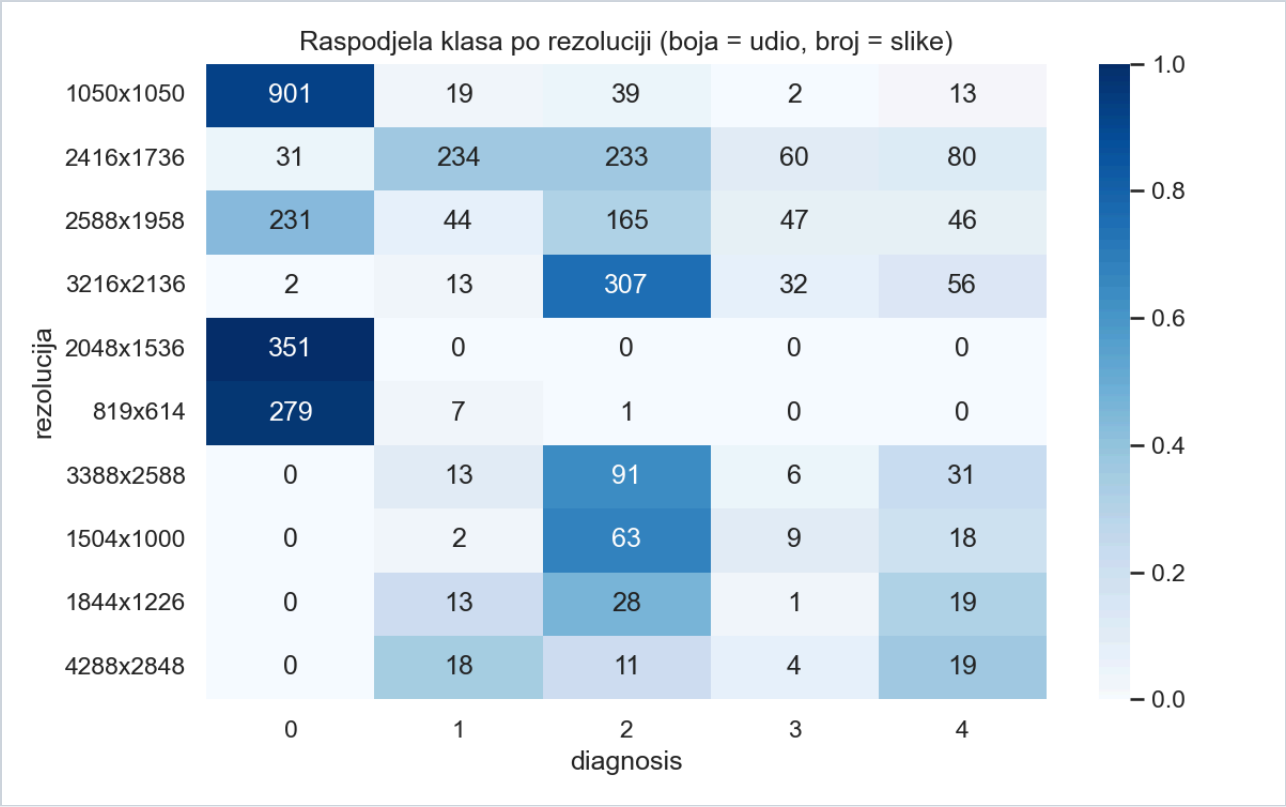
Značajka	ρ s `diagnosis`	Što zapravo mjeri
`width`	0,61	širina u pikselima — izravno opisuje rezoluciju
`aspect`	0,58	omjer stranica — razlikuje modele uređaja
`height`	0,56	visina u pikselima — izravno opisuje rezoluciju
`sharpness`	-0,55	sirova oštrina — mjeri rezoluciju, ne zamućenost
`file_kb`	0,52	veličina datoteke — raste s rezolucijom
`std_gray`	-0,31	kontrast unutar oka



Slika 3. Spearmanova korelacijska matrica izvedenih značajki i oznake.

Te korelacije **nisu znak da značajke nose medicinsku informaciju**. Sve su međusobno povezane i sve proizlaze iz iste stvari — rezolucije, odnosno uređaja kojim je snimka nastala. Širina, visina, omjer stranica i veličina datoteke izravno opisuju rezoluciju, a sirova oštrina s njom korelira -0,86, pa i ona zapravo mjeri rezoluciju. Drugim riječima, **uređaj kojim je snimka nastala predviđa dijagnozu**.

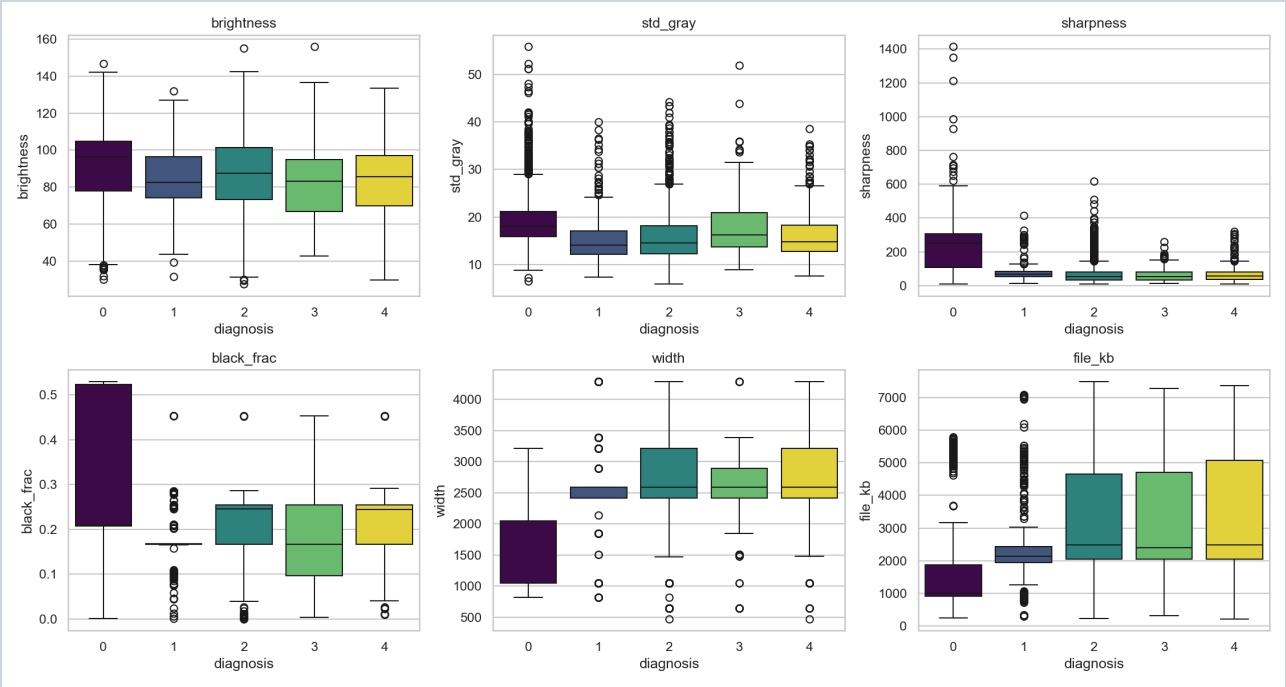
Slika 4 to pokazuje izravno: raspodjela klasa po najčešćim rezolucijama **izrazito odstupa** od ukupne raspodjele: najveće odstupanje udjela pojedine klase iznosi čak 50,7 postotnih poena. Najjasniji je primjer rezolucija 2048x1536, u kojoj klasa „No DR“ čini 100 % snimaka, naspram 49,3 % u cijelom skupu. Rezolucija je dakle **snažan posredni pokazatelj oznake** — model bi znatan dio točnosti mogao postići samim prepoznavanjem uređaja kojim je snimka nastala, ne gledajući patologiju. To je najozbiljniji oblik curenja koji smo u ovom skupu našli i nalaže obveznu protumjeru.



Slika 4. Raspodjela klasa unutar najčešćih rezolucija (boja = udio klase u toj rezoluciji, broj = apsolutni broj slika).

> **Zaključak o curenju.** Rezolucija je snažan posredni pokazatelj oznake. Model bi znatan dio točnosti mogao postići prepoznavanjem uređaja umjesto patologije — dobro proći na ovom skupu, a zatajiti na snimkama bilo kojeg drugog uređaja. Smatramo ovo najozbiljnijim problemom skupa. Protumjera je obrezivanje crnog ruba i svođenje svih snimaka na istu dimenziju, čime se eksplicitna informacija o rezoluciji uklanja iz ulaza. To ipak *ne* uklanja suptilnije tragove uređaja (razlučivost detalja, karakteristike šuma, nijansu boje), pa će u kasnijoj fazi trebati provjeriti i na čemu model doista temelji odluku.

Slika 5 pokazuje isto iz drugog kuta: klasa 0 odudara po širini i veličini datoteke, što nije medicinska razlika nego posljedica toga da je snimana drugim uređajima.



Slika 5. Raspodjele značajki po klasama.

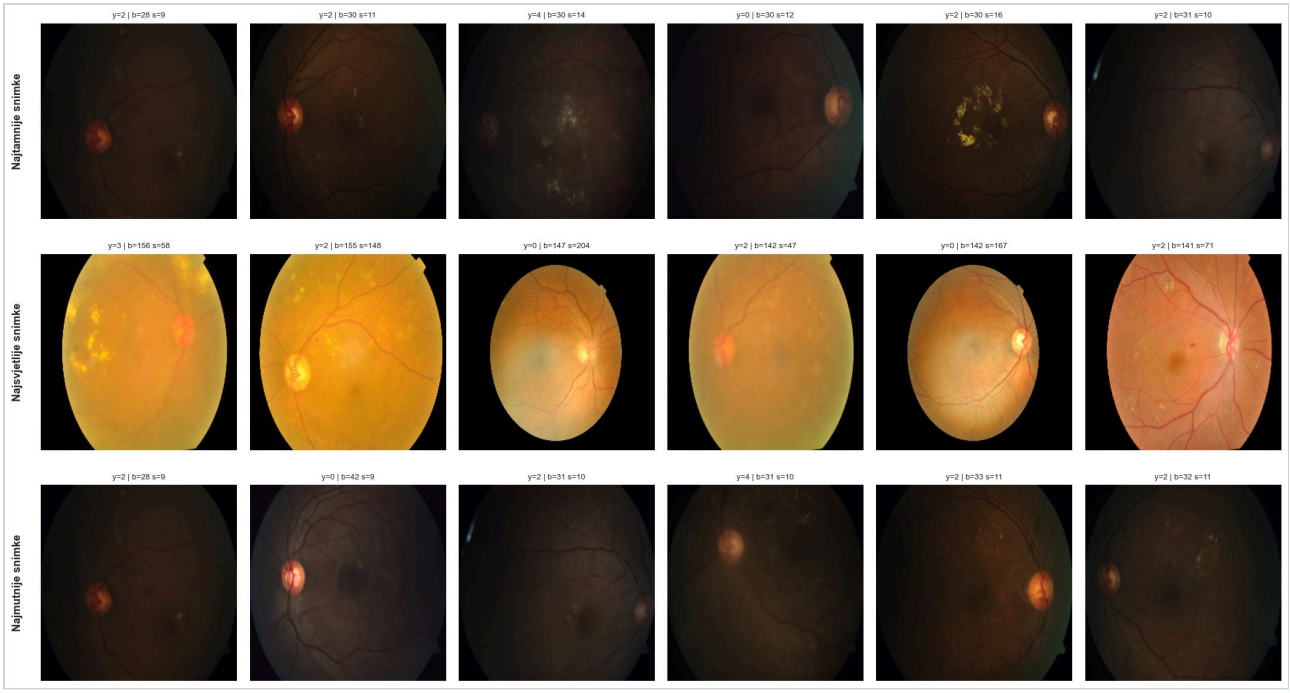
6. Problemi u podacima

6.1. Nedostajuće vrijednosti i integritet

Skup je u tom pogledu čist: nema nedostajućih vrijednosti (0), svakom zapisu odgovara postojeća datoteka (0 nedostajućih slika), a identifikatori su jedinstveni (0 duplikata). Imputacija nije potrebna.

6.2. Stršeće vrijednosti

Prema IQR kriteriju (Q1 − 1,5 IQR, Q3 + 1,5 IQR) nalazimo 8 stršećih vrijednosti po svjetlini, 175 po kontrastu i 94 po normaliziranoj oštrini. Vizualni pregled (Slika 6) pokazuje da **nisu neispravni zapisi nego snimke loše kvalitete**: nedovoljno osvijetljene, preeksponirane uz bljesak ili zamućene.



Slika 6. Najtamnije (gore), najsvjetlije (sredina) i najmutnije (dolje) snimke, s oznakom `y` te vrijednostima svjetline i oštrine.

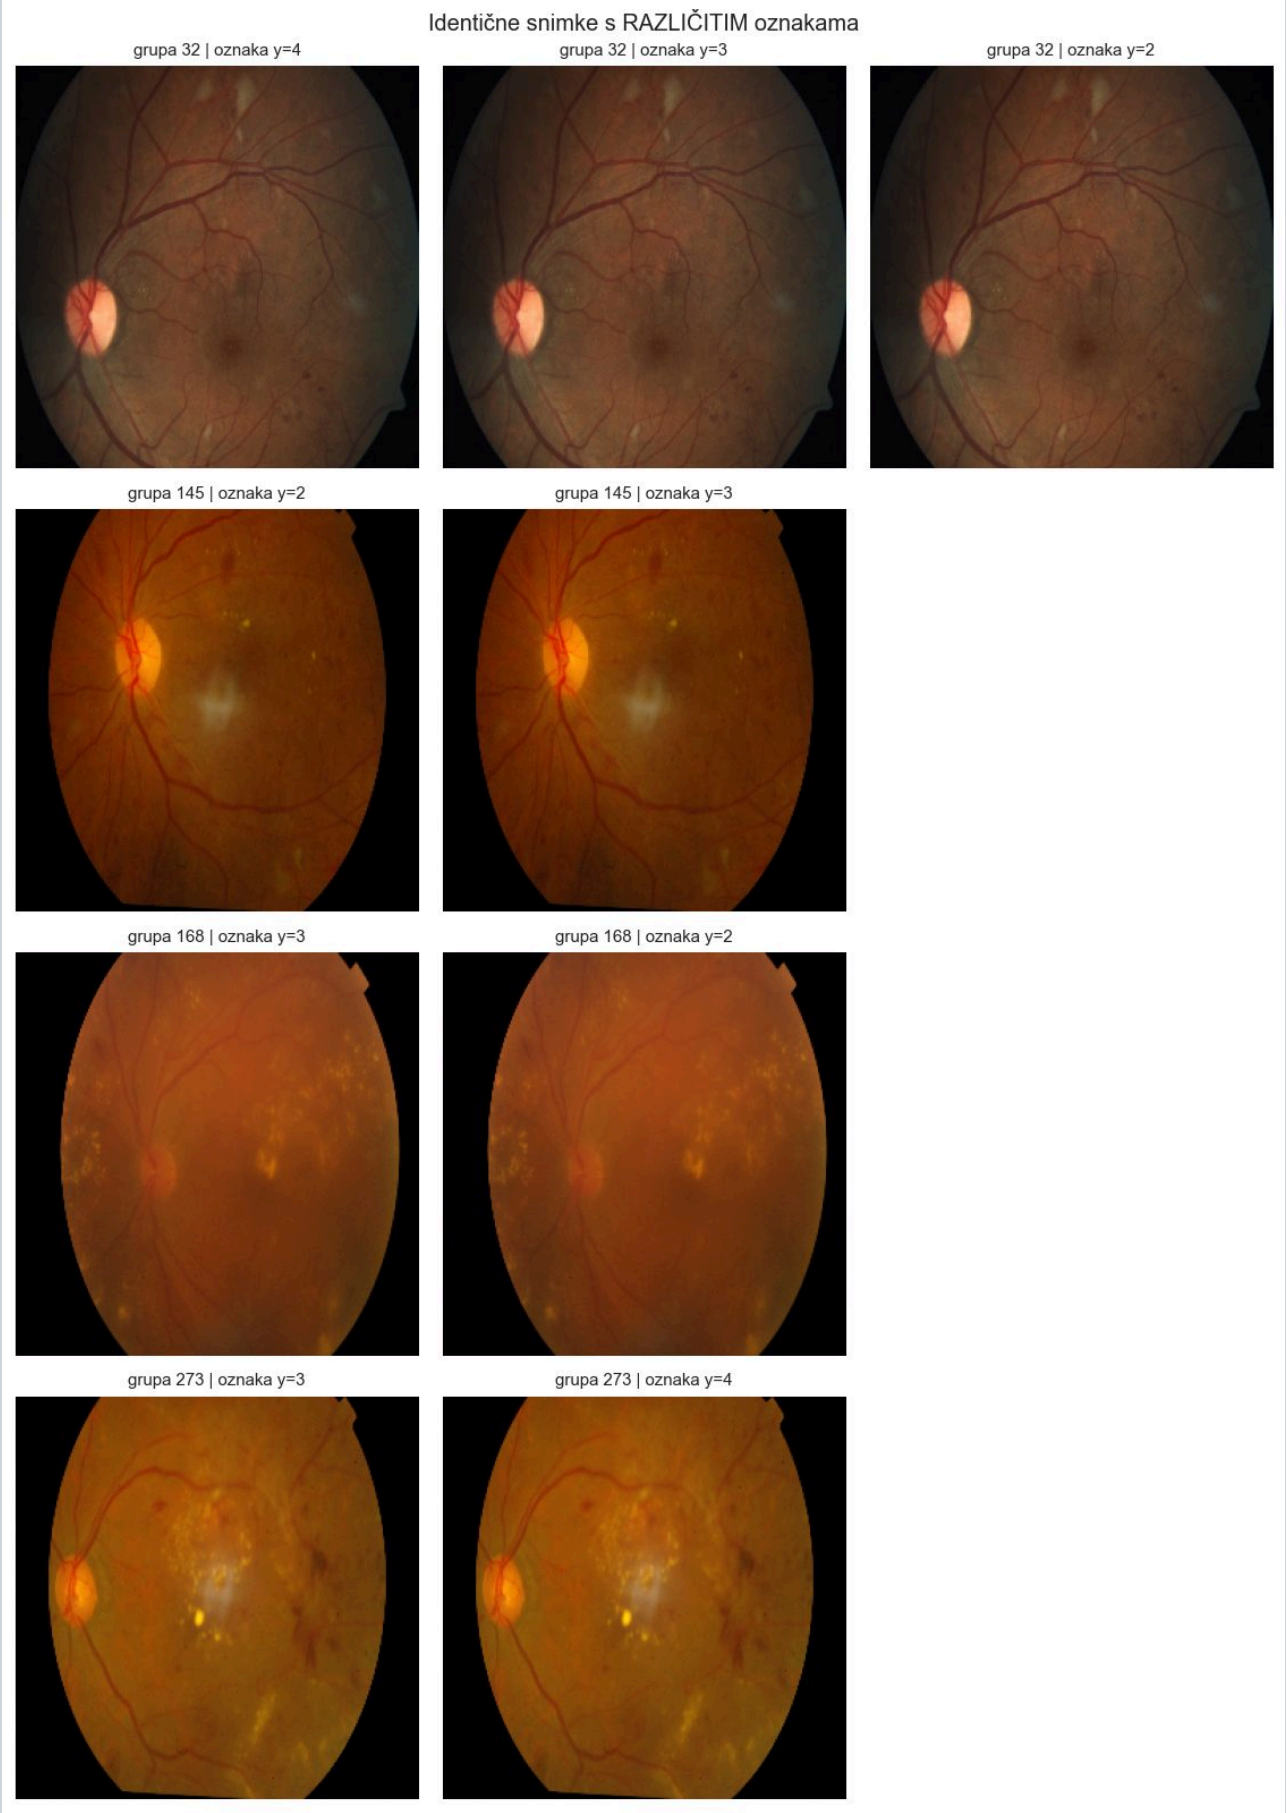
Te snimke **ne odbacujemo**: i u stvarnom probiru nastaju snimke loše kvalitete, pa bi njihovo uklanjanje popravilo mjere, ali ne i upotrebljivost modela.

6.3. Duplikati i šum u oznakama

Budući da nemamo identifikator pacijenta, duplikate tražimo po sadržaju slike, perceptualnim hashom (`phash`) uz spajanje u grupe strukturom *union-find*. **Prag smo odredili mjerenjem, a ne pretpostavkom**, jer se pokazao presudnim: fundus snimke strukturno su vrlo slične, pa labav prag spaja različita oka, a *union-find* tu pogrešku lančano širi. Pri pragu ≤ 4 najveća grupa narasla je na **187 snimaka**, koje su vizualnim pregledom bile različita oka, a ne duplikati.

Zato zahtijevamo **identičan hash** (prag 0) i odluku provjeravamo neovisno, izravnom usporedbom piksela: srednja apsolutna razlika *unutar* grupe iznosi **0** na skali 0–255, naspram **33,9** za nasumične parove. Razlika blizu nule potvrđuje da je riječ o istim snimkama.

Tako nalazimo **143 grupa** s ukupno **295 snimaka** (najveća ima 4), od čega **38 grupa ima različite oznake** za identične snimke (Slika 7). To je izravan dokaz **šuma u oznakama** i poklapa se s izmjerenim neslaganjem među ocjenjivačima [3]. Te snimke zadržavamo — uklanjanje bi značilo da sami presuđujemo koja je oznaka ispravna — ali njihovo postojanje postavlja realnu gornju granicu dostižne kvalitete.



Slika 7. Identične snimke (isti perceptualni hash, pikselska razlika ≈ 0) s različitim oznakama.

6.4. Sažetak

Tablica 5. Uočeni problemi i protumjere.

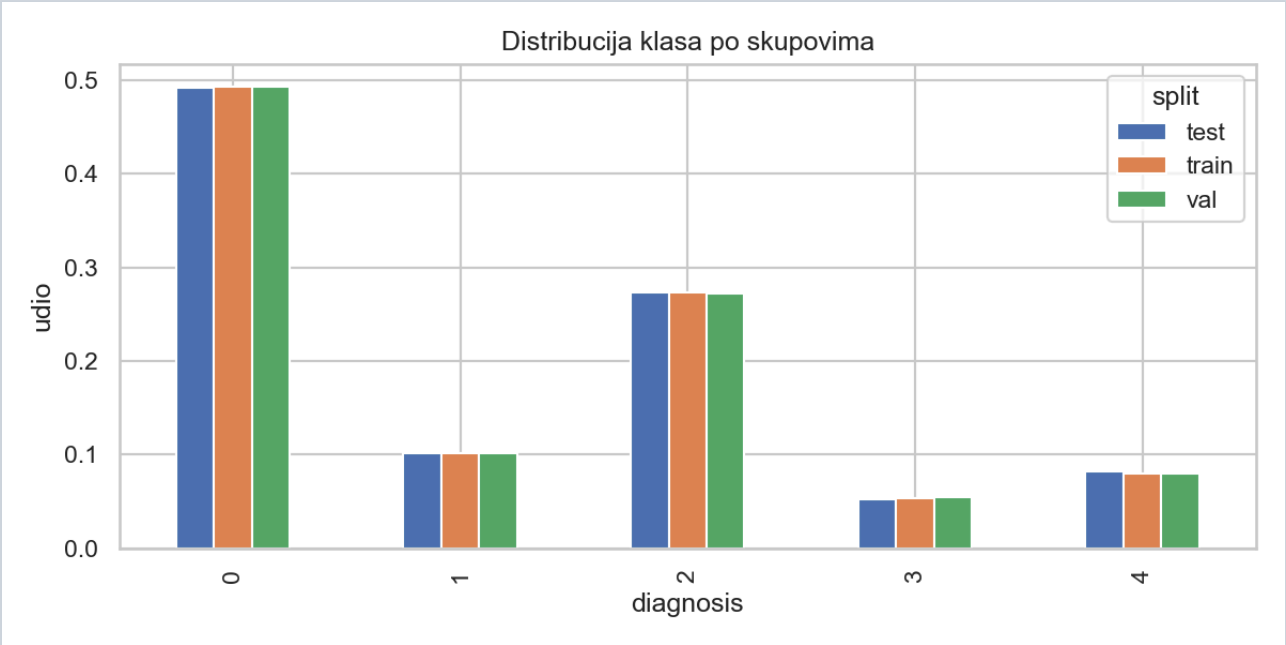
Problem	Nalaz	Protumjera
Rezolucija odaje oznaku	ρ do 0,61; pojedine rezolucije gotovo jednoklasne	obrezivanje ruba + jedinstvena dimenzija
Neuravnoteženost	omjer 9,4×	težine klasa, QWK umjesto točnosti
Duplikati	143 grupa / 295 snimaka	grupirana stratificirana podjela
Šum u oznakama	38 grupa s konfliktom	mjera tolerantna na blizu-pogreške
Varijabilna kvaliteta	izražen raspon svjetline i oštrine	zadržavamo, pratimo odvojeno
Nema ID pacijenta	nije dostupan	grupiranje po identičnom hashu (djelomično)

7. Podjela na skupove

Dijelimo približno **70 : 15 : 15** uz dva istodobna zahtjeva. **Stratifikacija** po oznaci nužna je zbog neuravnoteženosti — pri slučajnoj podjeli najrjeđa klasa mogla bi u validacijskom skupu imati svega nekoliko primjera. **Grupiranje** po grupi duplikata jamči da identične snimke završe u istom skupu. Oba zahtjeva zadovoljava `StratifiedGroupKFold`, primijenjen dvaput: prvo za testni skup, zatim za validacijski.

Tablica 6. Veličine skupova i udjeli klasa unutar skupa (%).

Skup	Broj slika	No DR	Mild	Moderate	Severe	Proliferative
Treniranje	2615	49,3	10,1	27,3	5,3	8
Validacija	523	49,3	10,1	27,2	5,4	8
Testiranje	524	49,2	10,1	27,3	5,2	8,2



Slika 8. Raspodjela klasa po skupovima — udjeli su gotovo jednaki, čime je stratifikacija potvrđena.

Provjerili smo programski da je **0 grupa duplikata u više od jednog skupa**. Podjela je zapisana u `outputs/split.csv` i fiksirana sjemenom (`SEED = 42`) kako bi svi kasniji eksperimenti koristili identične skupove.

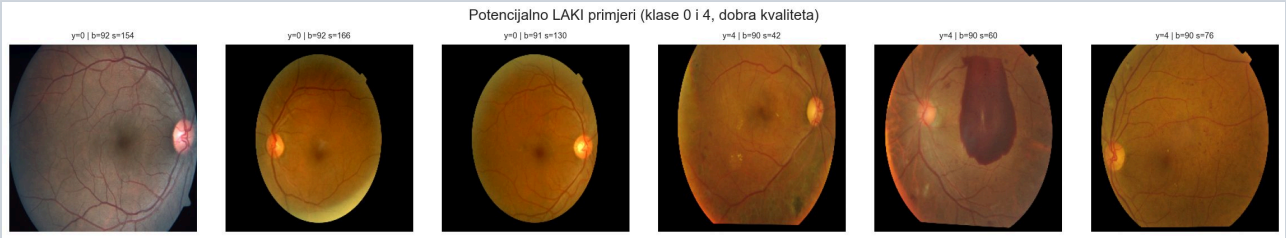
> **Ograničenje.** Time je isključeno curenje *egzaktnih duplikata*, ali ne i curenje na razini pacijenta. Bez identifikatora pacijenta ne možemo prepoznati dvije različite snimke istog oka, snimke lijevog i desnog oka iste osobe, niti ponovni pregled istog pacijenta. Takvi parovi mogu biti razdvojeni među skupovima, pa su mjere na testnom skupu vjerojatno **blago optimistične**. Navodimo to kao poznato ograničenje koje s raspoloživim metapodacima nije moguće ukloniti.

Za ublažavanje neuravnoteženosti izračunali smo težine klasa obrnuto proporcionalne njihovoj zastupljenosti u skupu za treniranje: No DR = 0,41, Mild = 1,98, Moderate = 0,73, Severe = 3,79, Proliferative = 2,49.

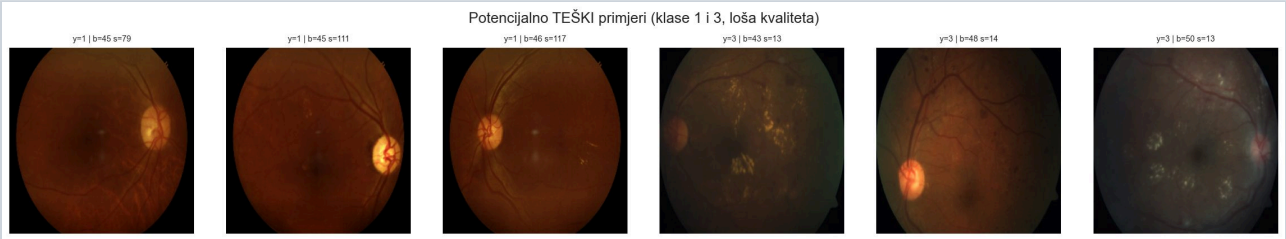
8. Očekivano „laki“ i „teški“ primjeri

Laki: oštre, dobro osvijetljene snimke klase 0 (mrežnica bez lezija) i klase 4 (opsežne promjene koje zahvaćaju velik dio slike). U oba slučaja odluka se temelji na obilježjima koja zauzimaju znatnu površinu, pa su dostupna i pri umjerenoj ulaznoj rezoluciji.

Teški: prije svega **klasa 1**, koju od klase 0 razdvaja prisutnost samih mikroaneurizama — lezija promjera nekoliko desetaka mikrometara, koje nakon svođenja na 224×224 piksela mogu obuhvatiti manje od jednog piksela. Zatim **granica 2–3**, u kliničkoj skali definirana *brojanjem* krvarenja po kvadrantima [1]. I snimke **loše kvalitete u bilo kojoj klasi**.



Slika 9. Očekivano laki primjeri (klase 0 i 4, dobra kvaliteta).



Slika 10. Očekivano teški primjeri (klase 1 i 3, loša kvaliteta).

Kvalitetu snimke ocijenili smo kompozitnom mjerom: prosjekom percentilnog ranga **normalizirane oštrine** i blizine medijalnoj svjetlini (dvosmjerno, jer su loše i pretamne i presvijetle snimke). Udio snimaka u najnižih 10 % te ocjene po klasama iznosi No DR = 11,6 %, Mild = 5,9 %, Moderate = 8,9 %, Severe = 9,3 %, Proliferative = 9,8 %. Razlike su **umjerene i ne prate težinu bolesti**: raspon je svega 5,7 postotnih poena, a najviše loših snimaka ima upravo klasa „No DR“, ne najteži stadiji. Kvaliteta snimke dakle **nije sustavno vezana uz stadij**, pa poteškoću na teškim primjerima pripisujemo prvenstveno suptilnosti lezija. Napominjemo da se taj zaključak mijenja ako se koristi sirova oštrina — tada se čini da teži stadiji imaju lošije snimke, no to je artefakt rezolucije, a ne stvarna razlika u kvaliteti.

> **Napomena o mjeri.** Mjera koristi `sharpness_norm` upravo zato što sirova oštrina mjeri rezoluciju (poglavlje 4). I tako normalizirana ostaje gruba: ne razlikuje zamućenje od pomaka ruke, neizoštrenosti ili zamućenja lećom, a budući da su rezolucija i klasa povezane (poglavlje 5), dio preostale razlike među klasama može i dalje biti posljedica uređaja. Zato je tumačimo kao *okvirni pokazatelj*, a ne kao pouzdanu ocjenu kvalitete.

9. Pregled relevantne literature

9.1. Definicija zadatka

Wilkinson i sur. (2003) [1] definiraju međunarodnu kliničku skalu težine DR, koja je izvor naših oznaka. Dva su nalaza bitna: skala je **uređena**, pa je prikladna mjera ona koja kažnjava pogreške proporcionalno udaljenosti stadija; i granice su definirane *brojanjem* lezija, a ne pukom prisutnošću, što objašnjava zašto je granica 2–3 teška i za ljude i za model.

9.2. Duboko učenje za probir DR

Gulshan i sur. (2016) [2] prvi su na velikoj skali pokazali da konvolucijska mreža postiže osjetljivost i specifičnost usporedive s oftalmolozima. Preuzimamo njihove metodološke odluke: vrednovanje na **kliničkom pragu** (klase ≥ 2) uz ROC analizu te ocjenjivanje svake snimke od više ocjenjivača. Rad pokazuje i da je za visoku kvalitetu potreban skup red veličine veći od našega, što naše rezultate smješta u realan okvir.

Voets i sur. (2019) [4] pokušali su taj rad reproducirati samo iz javnih podataka i **nisu dosegli izvorne rezultate**. Za nas je to upozorenje da razlike u skupu, postupku ocjenjivanja i predobradi objašnjavaju velik dio razlike među izvještajima, pa usporedbe brojki iz različitih radova nisu pouzdane.

9.3. Kvaliteta oznaka

Krause i sur. (2018) [3] najinformativniji su rad za našu analizu. Utvrdili su da su najčešći izvori neslaganja među ocjenjivačima **propuštene mikroaneurizme (36 %)**, artefakti (20 %) i pogrešno klasificirana krvarenja (16 %). Propuštene mikroaneurizme upravo su razlika između klasa 0 i 1, čime je naša pretpostavka o teškim primjerima (poglavlje 8) potvrđena neovisnim izvorom. Autori pokazuju i da **viša ulazna rezolucija** te kvalitetniji referentni standard dižu AUC s 0,934 na 0,986. Konačno, nesuglasje među stručnjacima objašnjava konfliktne oznake koje smo i sami našli među duplikatima (poglavlje 6.3).

9.4. Rad na istom skupu podataka

Tymchenko i sur. (2020) [5] opisuju rješenje za APTOS 2019 i izvještavaju QWK 0,925. Njihov je glavni nalaz da **iskorištavanje uređenosti oznaka** — istodobno učenje klasifikacije, ordinalne regresije i obične regresije — nadmašuje klasifikaciju u pet neovisnih razreda. Koriste i predtreniranje na većem skupu iz ranijeg natjecanja te ansambl s proširenjem pri predviđanju.

Naglašavamo da **njihov rezultat nije izravno usporediv s onim što ćemo mi izmjeriti**: 0,925 odnosi se na službeni testni skup natjecanja, čije oznake nisu javne, dok mi vrednujemo na vlastitoj podjeli označenog dijela. Isto vrijedi i za pobjednički rezultat 0,936. Te brojke uzimamo kao okvirnu naznaku dostižnog reda veličine, a ne kao mjerilo.

9.5. Ordinalnost i mjere uspješnosti

Galdran i sur. (2020) [6] razmatraju DR kao ordinalni problem i predlažu regularizaciju osjetljivu na cijenu pogreške, koja kažnjava pogreške proporcionalno udaljenosti stadija. Rad opravdava odabir QWK kao glavne mjere, jer kappa s kvadratnim težinama odgovara upravo takvoj strukturi cijene. **Araújo i sur. (2020)** [7] u radu *DR|GRADUATE* uz ocjenu daju i **procjenu nesigurnosti**, čime omogućuju izdvajanje nejasnih slučajeva za ljudski pregled — u probiru praktično vrjednije od same točnosti.

9.6. Predobrada i prijenosno učenje

Sarki i sur. (2021) [8] sistematiziraju uobičajene postupke predobrade fundus snimaka (obrezivanje, normalizacija osvjetljenja, izjednačavanje histograma, CLAHE, izdvajanje zelenog kanala). Za nas je ključno njihovo zapažanje da se predobrada u literaturi gotovo redovito primjenjuje, ali **rijetko izolirano vrednuje** — mijenja se zajedno s arhitekturom, pa se doprinosi ne mogu razlučiti. **Chilukoti i sur. (2024)** [10] daju uobičajene postavke prijenosnog učenja i ansambala te potvrđuju QWK kao standardnu mjeru u području.

9.7. Što iz literature preuzimamo

- **QWK kao glavna mjera**, uz vrednovanje na pragu upućivanja (klase ≥ 2) — [1], [2], [6], [10].
- **Rezolucija kao prvorazredni čimbenik**, a ne tehnička sitnica — [3].
- **Iskorištavanje uređenosti oznaka** umjesto pet neovisnih razreda — [5], [6].
- **Prijenosno učenje** zbog ograničene veličine skupa — [2], [5], [10].
- **Oprez pri usporedbi s objavljenim brojkama**, zbog različitih skupova i podjela — [4], [8].
- **Realna gornja granica** zbog šuma u oznakama — [3].

10. Zaključak analize

Skup sadrži 3 662 označenih snimaka fundusa s ordinalnom oznakom u pet razreda i **izrazito je neuravnotežen** (omjer 9,4×), zbog čega točnost nije prikladna mjera. Nema nedostajućih vrijednosti ni neispravnih zapisa.

Najvažniji nalaz jest da rezolucija snažno odaje oznaku (ρ do 0,61; pojedine rezolucije gotovo su jednoklasne). Postoji stvaran rizik da model nauči prepoznavati uređaj umjesto bolesti, pa su obrezivanje ruba i svođenje na jedinstvenu dimenziju obvezni, a kasnije će trebati provjeriti i na čemu model doista temelji odluku.

Pronašli smo **143 grupa identičnih snimaka**, od kojih 38 ima različite oznake — dokaz šuma u oznakama koji postavlja gornju granicu dostižne kvalitete. Podjela 70 : 15 : 15 provedena je stratificirano i grupirano, bez curenja egzaktnih duplikata (0 grupa u više skupova); curenje na razini pacijenta ostaje neprovjerivo jer identifikator pacijenta nije dostupan.

Najtežim primjerima smatramo razlikovanje klasa 0 i 1 te granicu 2–3, što potvrđuje i literatura [3].

Literatura

1. C. P. Wilkinson, F. L. Ferris 3rd, R. E. Klein i sur., „Proposed international clinical diabetic retinopathy and diabetic macular edema disease severity scales“, *Ophthalmology*, vol. 110, br. 9, str. 1677–1682, 2003.
2. V. Gulshan, L. Peng, M. Coram i sur., „Development and Validation of a Deep Learning Algorithm for Detection of Diabetic Retinopathy in Retinal Fundus Photographs“, *JAMA*, vol. 316, br. 22, str. 2402–2410, 2016. doi:10.1001/jama.2016.17216
3. J. Krause, V. Gulshan, E. Rahimy i sur., „Grader Variability and the Importance of Reference Standards for Evaluating Machine Learning Models for Diabetic Retinopathy“, *Ophthalmology*, vol. 125, br. 8, str. 1264–1272, 2018. (arXiv:1710.01711)
4. M. Voets, K. Møllersen, L. A. Bongo, „Reproduction study using public data of: Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs“, *PLOS ONE*, vol. 14, br. 6, e0217541, 2019.
5. B. Tymchenko, P. Marchenko, D. Spodarets, „Deep Learning Approach to Diabetic Retinopathy Detection“, arXiv:2003.02261, 2020.
6. A. Galdran, J. Dolz, H. Chakor i sur., „Cost-Sensitive Regularization for Diabetic Retinopathy Grading from Eye Fundus Images“, arXiv:2010.00291, 2020.
7. T. Araújo, G. Aresta, L. Mendonça i sur., „DR|GRADUATE: Uncertainty-aware deep learning-based diabetic retinopathy grading in eye fundus images“, *Medical Image Analysis*, vol. 63, 101715, 2020. (arXiv:1910.11777)
8. R. Sarki, K. Ahmed, H. Wang, Y. Zhang, J. Ma, K. Wang, „Image Preprocessing in Classification and Identification of Diabetic Eye Diseases“, *Data Science and Engineering*, vol. 6, br. 4, str. 455–471, 2021. doi:10.1007/s41019-021-00167-z
9. APTOS 2019 Blindness Detection, Kaggle, 2019. https://www.kaggle.com/competitions/aptos2019-blindness-detection
10. S. V. Chilukoti, L. Shan, V. S. Tida, A. S. Maida, X. Hei, „A reliable diabetic retinopathy grading via transfer learning and ensemble learning with quadratic weighted kappa metric“, *BMC Medical Informatics and Decision Making*, vol. 24, čl. 37, 2024. doi:10.1186/s12911-024-02446-x